IA de détection précoce du diabète

Projet tabulaire • Classification binaire • Contexte hospitalier

Points clés du dossier :
- 800 lignes, 16 colonnes
- forte asymétrie de classes
- fuite de cible détectée
- pipeline industrialisable

Message central

En santé, un bon score ne suffit pas.

Le modèle doit rester crédible, explicable et utilisable dans un scénario clinique réaliste.

1. Problème métier et objectif

Ce que le notebook cherche à démontrer

Contexte

- Un hôpital universitaire veut détecter plus tôt les patients à risque de diabète.
-
- Le modèle est pensé comme un outil d'aide à la décision, jamais comme un diagnostic autonome.
-
- Le cas d'usage se limite à des données cliniques tabulaires anonymisées.

Valeur attendue

- Mieux orienter les patients vers un contrôle médical approfondi.
-
- Aider à la priorisation en contexte de charge hospitalière.
-
- Rester explicable, traçable et industrialisable.

Critère de réussite : un pipeline complet et un raisonnement méthodologique défendable devant un jury.

2. Jeu de données et qualité initiale

Faits saillants

- 800 lignes et 16 colonnes.
-
- Aucune valeur manquante détectée.
-
- Aucun doublon technique exact.
-
- Variables biométriques, biologiques, cliniques et comportementales.

Variables à surveiller

- patient_id : identifiant technique, non prédictif.
- diabetes_type et diabetes_cause : très probablement post-diagnostic.

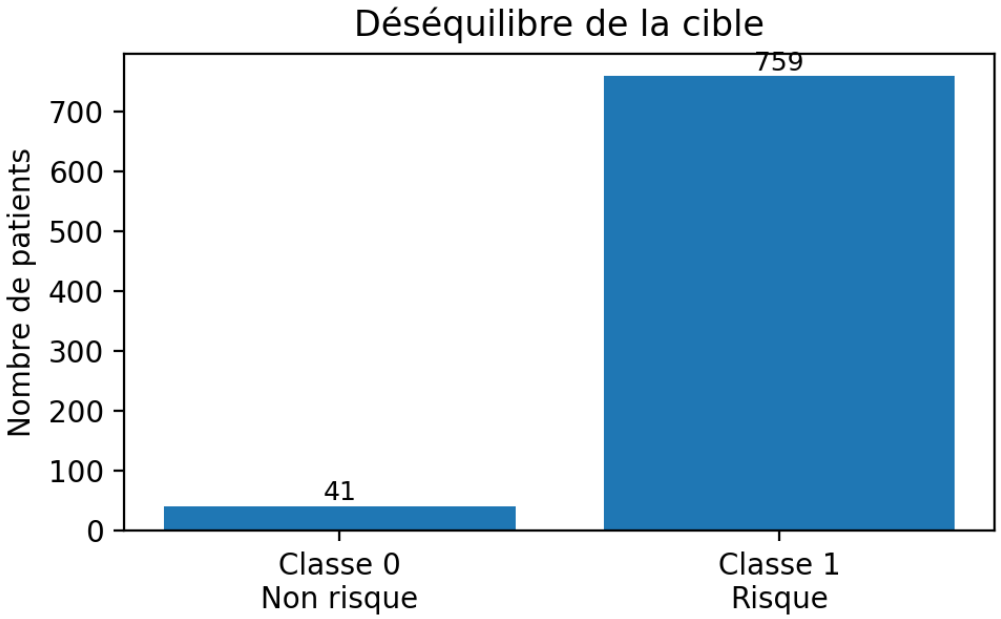

Cible très déséquilibrée : 759 positifs vs 41 négatifs, soit ~94,9 % de classe 1.

3. Analyse exploratoire : ce que les données racontent

Trois constats structurants ressortent du notebook

1. Déséquilibre majeur

La classe positive domine massivement. Un modèle naïf peut donc obtenir un recall élevé sans vraie capacité de discrimination.

2. Signaux plausibles

Les écarts de moyennes sur glucose, HbA1c, tension ou score rétinien restent médicalement cohérents, mais modérés.

3. Fuite de cible

Les colonnes diabetes_type et diabetes_cause séparent presque parfaitement la cible. Les garder reviendrait à donner la réponse au modèle.

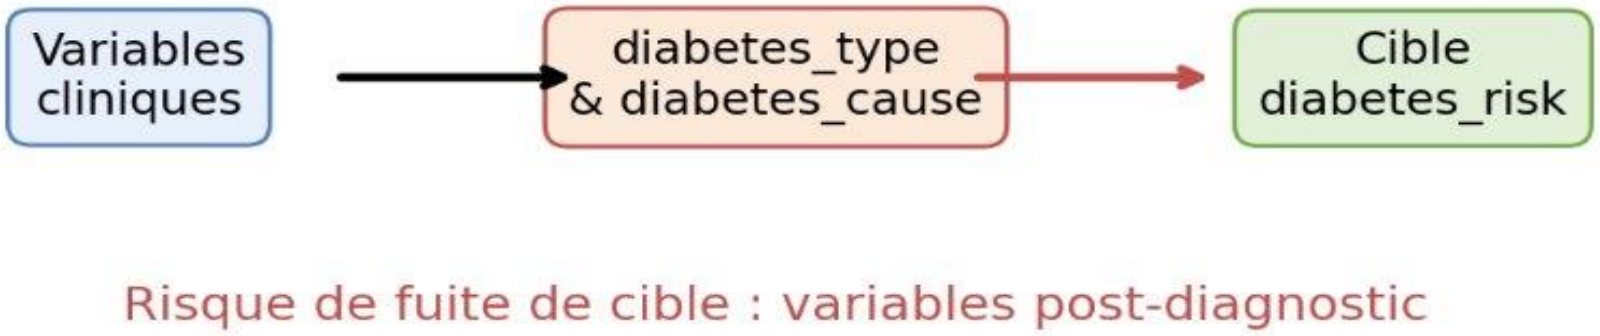

4. Préparation des données

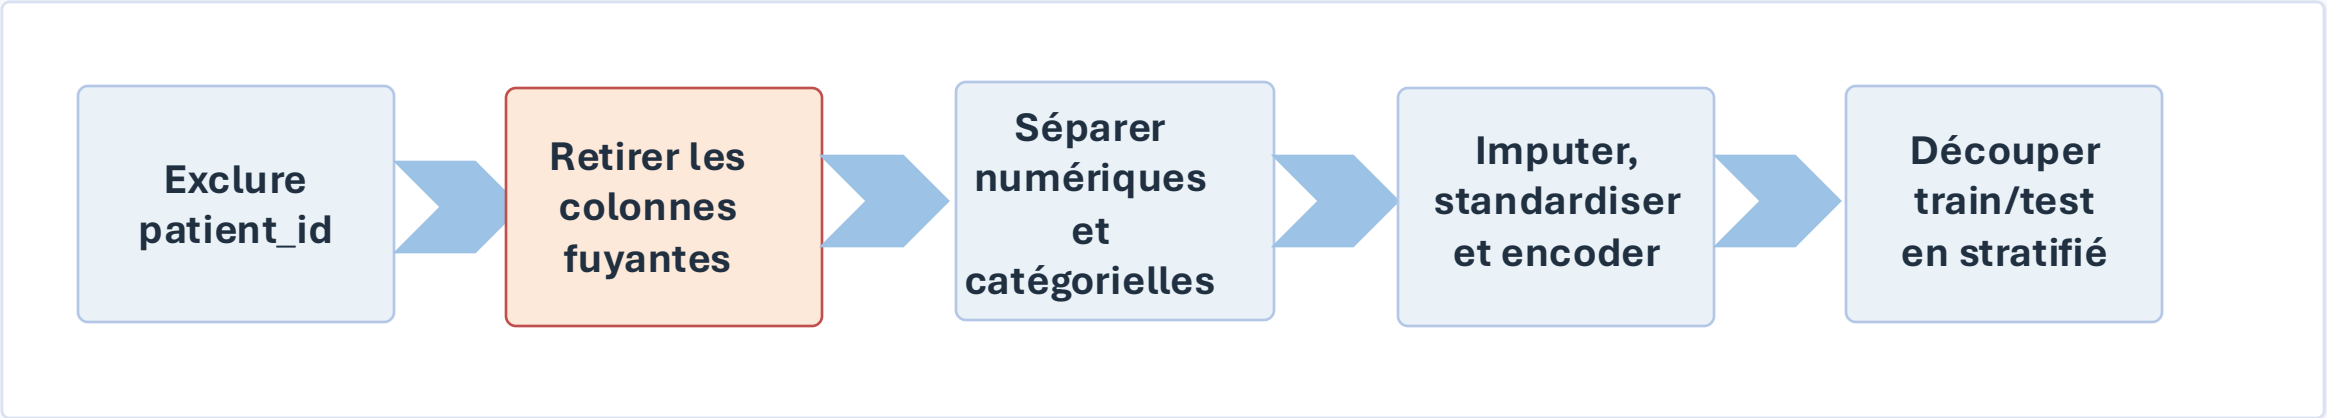

Principes de gouvernance

- Transformations documentées et versionnées.
-
- Pipeline exécutable de bout en bout.
-
- Préparation séparée de l'apprentissage pour faciliter le déploiement.

5. Modèles comparés et logique d’évaluation

Le notebook privilégie des modèles défendables en contexte médical

Familles testées

- DummyClassifier pour la baseline minimale.
-
- Régression logistique pondérée.
-
- Arbre de décision pondéré.
-
- Forêt aléatoire pondérée.
-
- Gradient Boosting mentionné dans la démarche.

Métriques retenues

- Recall / sensibilité
-
- Précision
-
- F1-score
-
- Spécificité
-
- ROC-AUC
-
- Balanced accuracy

Pourquoi ce choix ?

Avec 94,9 % de cas positifs, regarder uniquement le recall serait trompeur. La spécificité et la balanced accuracy sont indispensables pour juger la capacité réelle à reconnaître les cas négatifs.

Résultat attendu

Un score de risque probabiliste est plus utile qu'une décision binaire brute pour l'usage métier.

6. Résultats : lire les scores avec prudence

Le dataset favorise artificiellement les stratégies qui prédisent presque tout en positif

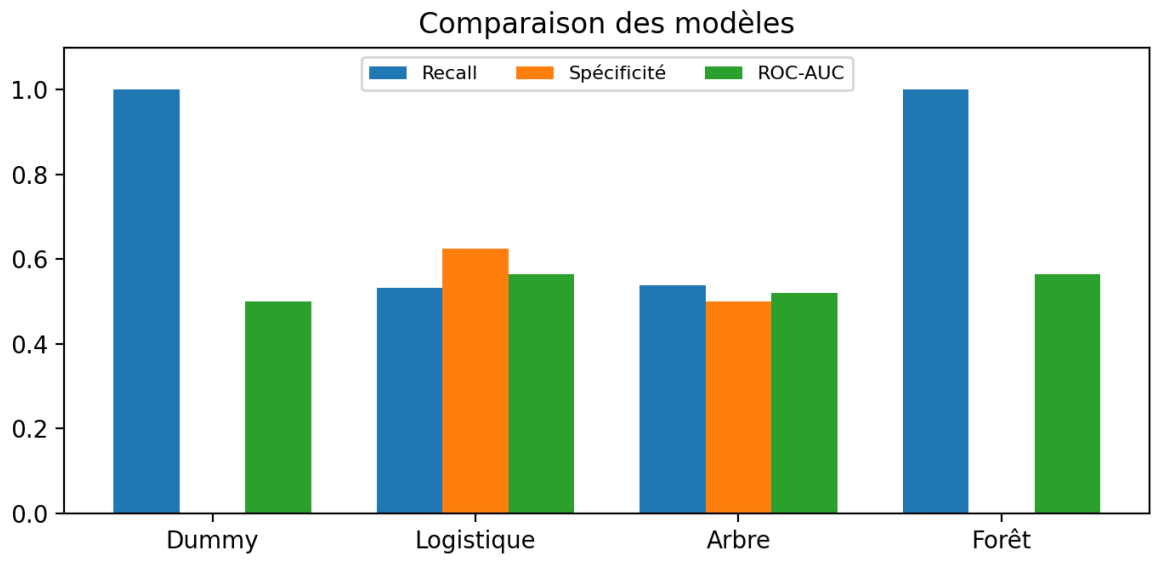

Lecture La baseline Dummy et la forêt aléatoire atteignent un recall de 1,00 mais une spécificité de 0,00 : elles ne reconnaissent pas les négatifs.

Modèle défendable :

Régression logistique pondérée

Recall ≈ 0,533
Spécificité ≈ 0,625
ROC-AUC ≈ 0,565

Pourquoi ? Parce qu'elle offre le compromis le plus honnête entre interprétabilité et réalisme clinique, sans masquer les limites du jeu de données.

7. Mise en production envisagée

Le notebook va au-delà du modèle et propose une trajectoire d'industrialisation

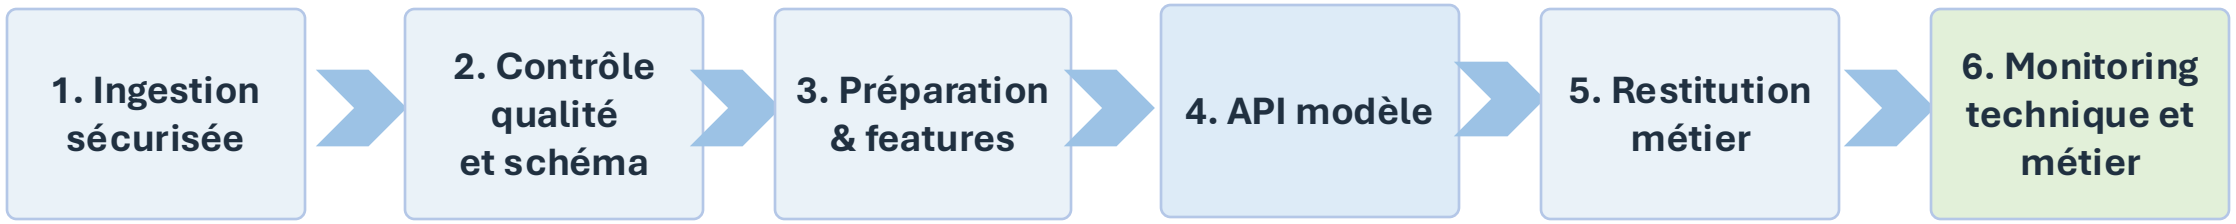

Contraintes à intégrer

- Latence faible, versioning du modèle, journalisation et sécurité des données de santé.
- Validation médicale, supervision humaine et auditabilité avant toute généralisation.
- Formation des utilisateurs et arbitrage avec les parties prenantes.

8. Limites, risques et suite recommandée

La valeur du projet tient autant à ses garde-fous qu'à son pipeline

Limites identifiées

- Dataset probablement peu représentatif d'une population hospitalière réelle.
-
- Absence de série temporelle et d'images rétiniennes natives.
-
- Déséquilibre extrême des classes.
-
- Fuite de cible détectée sur des variables post-diagnostic.

Recommandations

- Enrichir les données et valider la représentativité clinique.
-
- Suivre les métriques dans le temps avec une logique MLOps.
-
- Réentraîner selon des seuils définis en amont.
-
- Intégrer progressivement le modèle sous supervision humaine.

Conclusion

mieux vaut un modèle plus modeste mais crédible qu’un modèle excellent sur le papier et inutilisable en pratique.